沪深300历史成分股行情与因子数据（2016 – 2022）

公开数据集覆盖 2016-01-04 至 2022-12-30 的 1703
个交易日。数据包含股票日行情、因子、当日成分股的行业与权重，以及沪深300指数基准。

目录与规模

```
data/
├── MarketData/<年>/<月>/<年月>.parquet
├── MarketDataRawOpen/<年>/<月>/<年月>.parquet
├── Factor33_winsor/<年>/<月>/<年月>.parquet
├── Barra_factor/<年>/<月>/<年月>.parquet
├── Barra_factor/<年>/barra_cne5_<年>.csv
├── HS300_index/<年>/hs300_index_<年>.csv
├── HS300_industry/<年>/hs300_industry_<年>.csv
└── HS300_weight/<年>/hs300_weight_<年>.csv
```

<年> 为 2016 至 2022；<月> 为 01 至 12，例如 data/MarketData/2022/01/202201.parquet。CSV 使用 GBK 编码，读取时可指定 gb18030；Parquet 列名使用 UTF-8。

数据表	格式	文件数	行数	列数	每交易日记录数
MarketData	月度 Parquet	84	590,238	10	327 – 354
MarketDataRawOpen	月度 Parquet	84	590,238	3	327 – 354
Factor33_winsor	月度 Parquet	84	590,238	36	327 – 354
Barra_factor	月度 Parquet；另有年度 CSV	84 + 7	510,900	13	300
HS300_index	年度 CSV	7	1,703	7	1
HS300_industry	年度 CSV	7	510,900	5	300
HS300_weight	年度 CSV	7	510,900	6	300

主键与股票池

- 股票表以（日期，代码）标识一条记录。日期 为 YYYYMMDD 整数（如 20220104）；代码 带 SH 或 SZ 市场前缀。
- MarketData 与 Factor33_winsor 两表采用当年度沪深300成分股并集：只要股票在某年曾入选，该年数据中就可能包含它在非成分期间的记录。因此，这两表的全部股票不能直接当作某日的沪深300成分股，建议选手进行恰当的数据处理。
- Barra_factor 采用当日沪深300成分股，每天 300 只，键是前两表的子集。
- 需要严格的当日成分股股票池时，应使用 Barra_factor、HS300_industry 或 HS300_weight 的日期、代码键筛选。

字段

MarketData

字段	含义
日期，代码，名称	交易日、证券代码、证券简称
open，high，low，close	日开高低收价格；原始数据说明标注为后复权价
volume，amount	成交股数、成交金额（元）；原始数据说明标注为未复权
is_suspend	停牌标记，1 表示停牌

MarketDataRawOpen

此表提供与 MarketData 同一（日期，代码）股票池的未复权开盘价，用于需要
原始开盘价的标签或成交价计算。它不包含 high、low、close、volume、amount 或
is_suspend，停牌状态仍应从 MarketData 读取。

字段	含义
日期，代码	交易日、证券代码

字段	含义
open	未复权开盘价；在程序中可映射为 raw_open

MarketData.open 是后复权开盘价，MarketDataRawOpen.open 是未复权开盘价。两张

表应按 日期、代码 连接，不能直接将两列视为同一价格口径。

Factor33_winsor

此表有 3 个标识列（日期, 代码, 名称）和 33 个因子/状态列。原始数据说明指出，数值因子按交易日横截面进行了 3σ 缩尾。

分组	字段
量价与技术指标	turn, change_ratio, daily_return, momentum_5, reversal_5, volatility_5, sma_20, ema_20, macd_diff_12_26_9, macd_dea_12_26_9, macd_hist_12_26_9, rsi_12, kdj_k_9_3_3, kdj_d_9_3_3, bias_20, cci_14, atr_14
市值与财务	total_market_cap, float_market_cap, pe_ttm, pb, ps_ttm, roe_avg_ttm, roa_avg_ttm, gross_profit_rate_ttm, net_profit_rate_ttm, debt_to_asset_lf, current_ratio_lf
风险	beta_000300SH_22
状态	list_days, is_suspend, is_st, is_new

Barra_factor

这些因子是当日横截面的 0－1 百分位排名。

沪深300参考数据

数据表	字段	口径
HS300_index	日期, 代码, 名称, 昨收, 收盘, 涨跌幅, 对数收益	指数代码为 SH000300；涨跌幅 用百分数，对数收益 用小数
HS300_industry	日期, 代码, 名称, 行业名称, 行业代码	申万行业分类
HS300_weight	日期, 代码, 名称, 权重, 权重来源, 指数成份日	权重 用百分数，每个交易日合计约为 100；来源包括 指数提供商、天软预估、估算补齐

读取示例

从本 README 所在目录运行，建议安装 pandas 和 pyarrow：

```
from pathlib import Path
import pandas as pd

data = Path("data")
market = pd.read_parquet(data / "MarketData/2022/01/202201.parquet")
raw_open = pd.read_parquet(data / "MarketDataRawOpen/2022/01/202201.parquet")
factors = pd.read_parquet(data / "Factor33_winsor/2022/01/202201.parquet")
barra = pd.read_parquet(data / "Barra_factor/2022/01/202201.parquet")
weights = pd.read_csv(
    data / "HS300_weight/2022/hs300_weight_2022.csv",
    encoding="gb18030",
    dtype={"代码": "string"},
)

day = 20220104
daily_market = market.loc[market["日期"].eq(day)]
daily_raw_open = raw_open.loc[raw_open["日期"].eq(day)]
daily_weights = weights.loc[weights["日期"].eq(day)]
```

跨表连接时使用 日期、代码 两列，并留意不同表的股票池。年度 CSV 和月度 Parquet 是两种文件组织方式；读取多个文件后应按日期排序。